

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ

Đề tài: Hệ thống phân vùng thực thể chẩn đoán bệnh trên lá cây nông nghiệp đặc
sản cà phê và lúa

Môn học: CSC14005 - Nhập môn học máy

Sinh viên thực hiện:

Nguyễn Hồ Anh Tuấn - 23120185

Lê Xuân Trí - 23120099

Đàm Tiến Đạt - 23120118

Tổng Thanh Phúc - 23120158

Dương Tuấn Anh - 23120208

Giáo viên hướng dẫn:

Thầy Bùi Tiến Lên

Ngày 17 tháng 7 năm 2026

Mục lục

Danh sách bảng	1
Danh sách hình vẽ	2
Bảng thuật ngữ	3
Thông tin nhóm và Phân công công việc	6
1 Giới thiệu	6
1.1 Phân tích Vấn đề (Problem Definition)	6
1.2 Mục tiêu của Đồ án	8
1.3 Tổng quan về Phương pháp	9
2 Thu thập và phân tích dữ liệu	10
2.1 Nguồn và phương pháp thu thập	10
2.2 Tiền xử lý và làm sạch	11
2.3 Phân tích và khám phá dữ liệu	11
2.3.1 Phân bố lớp và mức độ mất cân bằng	12
2.3.2 Độ phân giải, tỉ lệ khung hình và annotation	12
2.3.3 Trực quan hóa mẫu bệnh	13
2.3.4 Độ sáng, kênh màu và cặp bệnh dễ nhầm lẫn	14
3 Lựa chọn và Huấn luyện Mô hình	18
3.1 Chuẩn bị Dữ liệu cho Mô hình	18
3.2 Lựa chọn và Kiến trúc Mô hình	18
3.3 Cấu hình Huấn luyện	20
3.4 Tinh chỉnh siêu tham số	20
4 Kết quả và Thảo luận	21
4.1 Kết quả Thực nghiệm	21
4.2 So sánh và Thảo luận	23
4.2.1 Đánh giá Trade-off và Lựa chọn Mô hình	23
4.2.2 Cải thiện với RayTune và ASHA	23
4.2.3 Phân tích Ma trận nhầm lẫn (Confusion Matrix)	23
4.2.4 Hiện tượng Overfitting và Underfitting	24

5	Xây dựng và Triển khai Ứng dụng	25
5.1	Kiến trúc Hệ thống	25
5.2	Đóng gói và Tích hợp Mô hình	26
5.3	Giao diện và Chức năng	27
5.4	Triển khai trên GCP	27
5.4.1	Minh chứng trạng thái vận hành	31
5.5	Đánh giá và Giới hạn Triển khai	31
6	Kết luận	32
6.1	Tóm tắt Kết quả	32
6.2	Hạn chế	32
6.3	Hướng phát triển	33
	Tài liệu tham khảo	35
A	Minh chứng bổ sung cho Chương 5	37

Danh sách bảng

1	Bảng đối chiếu thuật ngữ Anh - Việt và chuyên ngành	3
2	Bảng phân công công việc chi tiết của các thành viên	6
3	Tổng hợp kết quả làm sạch dữ liệu trên toàn bộ tập ảnh	11
4	Phân bố chi tiết số ảnh theo lớp và miền dữ liệu sau làm sạch	11
5	Phân bố số lượng ảnh theo tập con, miền và lớp bệnh	18
6	Tổng quan và đặc điểm của năm mô hình segmentation được thử nghiệm	19
7	Thiết lập cấu hình huấn luyện chung cho năm mô hình	20
8	Cấu hình tham số riêng theo yêu cầu kiến trúc từng mô hình	21
9	Không gian tìm kiếm siêu tham số cho YOLO26m-seg bằng Ray Tune	21
10	So sánh hiệu năng của các mô hình trên tập dữ liệu Lúa (Rice)	22
11	So sánh hiệu năng của các mô hình trên tập dữ liệu Cà phê (Coffee)	22
12	Kết quả của YOLO26-seg trước và sau khi tinh chỉnh bằng RayTune	23
13	Các thành phần chính trong kiến trúc ứng dụng	25
14	Workload và lưu trữ trên cụm k3s	30

Danh sách hình vẽ

1	Sơ đồ quy trình tổng thể 9 bước của hệ thống chẩn đoán bệnh cây trồng	9
2	Sơ đồ pipeline thu thập và gán nhãn dữ liệu theo hướng human-in-the-loop.	10
3	Phân bố số lượng ảnh và tỉ lệ phần trăm theo lớp bệnh trên hai miền lúa và cà phê.	12
4	Phân tích kích thước ảnh: quan hệ width-height, phân phối chiều rộng và tỉ lệ khung hình theo miền dữ liệu.	13
5	Phân tích annotation COCO: số thực thể trên mỗi ảnh, tỉ lệ diện tích bounding box và phân phối kích thước vùng bệnh.	14
6	Một số mẫu ảnh tiêu biểu theo từng lớp bệnh trên miền lúa.	15
7	Một số mẫu ảnh tiêu biểu theo từng lớp bệnh trên miền cà phê.	16
8	Phân phối độ sáng, giá trị trung bình kênh RGB và độ tương phản theo lớp bệnh trên hai miền dữ liệu.	17
9	So sánh histogram RGB và khoảng cách Bhattacharyya giữa các cặp bệnh dễ nhầm lẫn trên lúa và cà phê.	17
10	Đường cong học tập (Loss và mAP) của YOLO26-seg qua các vòng lặp (epochs)	22
11	Ma trận nhầm lẫn (Confusion Matrix) của mô hình YOLO26-seg	24
12	Kiến trúc triển khai ứng dụng trên GCP và k3s	26
13	Giao diện chẩn đoán và xác thực người dùng	27
14	Kết quả dự đoán và khuyến nghị cho ảnh lá cà phê	28
15	Danh sách cơ sở tri thức bệnh trên lúa và cà phê	29
16	Các bước CI/CD hoàn tất thành công trên GitHub Actions	30
17	Trạng thái cụm k3s và Helm release trên GCP	31
18	Tài liệu API và nội dung cơ sở tri thức mở rộng	37

Bảng thuật ngữ

Dưới đây là bảng đối chiếu và giải nghĩa các thuật ngữ viết tắt, thuật ngữ chuyên ngành tiếng Anh được sử dụng trong báo cáo đề án, kèm theo dịch nghĩa hoặc giải nghĩa trong tiếng Việt.

Bảng 1: Bảng đối chiếu thuật ngữ Anh - Việt và chuyên ngành

Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt
Annotation	Gán nhãn hoặc chú giải dữ liệu (tọa độ, nhãn lớp hoặc mặt nạ phân vùng phục vụ huấn luyện và đánh giá mô hình).
ASHA (Asynchronous Successive Halving)	Thuật toán dừng sớm bất đồng bộ phục vụ tìm kiếm siêu tham số tối ưu.
Aspect ratio	Tỉ lệ khung hình (tỉ lệ giữa chiều rộng và chiều cao của ảnh).
Attention	Cơ chế tập trung (cơ chế chú ý giúp mô hình tập trung vào các vùng thông tin quan trọng trên ảnh).
Batch size	Kích thước lô (số lượng mẫu dữ liệu được xử lý trong một lần cập nhật trọng số của mô hình).
Bounding box	Khung bao / Hộp giới hạn (xác định vị trí và bao quanh đối tượng hoặc vùng bệnh được phát hiện trên ảnh).
Classification	Bài toán phân loại ảnh (gán một hoặc nhiều nhãn lớp cho toàn bộ bức ảnh).
Convolutional Neural Network (CNN)	Mạng thần kinh tích chập (học các đặc trưng hình ảnh cục bộ thông qua phép tích chập).
Data Augmentation	Tăng cường dữ liệu (tạo thêm dữ liệu huấn luyện bằng các phép biến đổi hình học, hình thái hoặc quang học ảnh).
Dataset	Tập dữ liệu (bao gồm tập ảnh và nhãn đi kèm được sử dụng để huấn luyện, kiểm tra và đánh giá mô hình).
Dice Score	Chỉ số đo lường độ trùng khớp giữa hai vùng mặt nạ (tương đương với F1-score ở cấp độ pixel).

Bảng 1 (tiếp theo): Bảng đối chiếu thuật ngữ

Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt
Domain shift	Sự dịch chuyển miền dữ liệu (khác biệt phân phối dữ liệu giữa tập huấn luyện và thực tế).
Edge devices	Thiết bị biên (thiết bị phần cứng đầu cuối có tài nguyên tính toán giới hạn).
Epoch	Vòng lặp huấn luyện (một chu kỳ mô hình học qua toàn bộ tập dữ liệu huấn luyện).
Gradient accumulation	Tích lũy đạo hàm (kỹ thuật gom đạo hàm qua nhiều bước nhỏ để mô phỏng kích thước lô lớn).
Human-in-the-loop	Quy trình có con người tham gia kiểm duyệt và tinh chỉnh kết quả đề xuất của mô hình AI.
Hyperparameter tuning	Tinh chỉnh siêu tham số (tối ưu hóa các tham số thiết lập cấu hình trước khi huấn luyện mô hình).
Instance Segmentation	Phân vùng thực thể (phân lớp đối tượng ở cấp độ điểm ảnh và tách biệt rõ từng thực thể độc lập cùng lớp).
Learning rate	Tốc độ học (bước nhảy cập nhật trọng số trong thuật toán tối ưu hóa).
Letterbox	Chuẩn hóa kích thước ảnh giữ nguyên tỷ lệ khung hình thực tế bằng cách thêm viền đệm.
Loss function	Hàm mất mát (hàm đánh giá độ lệch giữa dự đoán của mô hình và nhãn thực tế).
mAP (Mean Average Precision)	Độ chính xác trung bình trung (chỉ số đánh giá hiệu năng của các mô hình phát hiện vật thể).
Mask	Mặt nạ (vùng điểm ảnh nhị phân xác định hình thái chi tiết và chính xác của thực thể).
mIoU (Mean Intersection over Union)	Tỷ lệ giao trên hợp trung bình (chỉ số đánh giá độ trùng khớp của mặt nạ phân vùng).

Bảng 1 (tiếp theo): Bảng đối chiếu thuật ngữ

Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt
ONNX (Open Neural Network Exchange)	Chuẩn trao đổi mạng nơ-ron mở giúp tối ưu hóa suy luận và triển khai mô hình trên nhiều phần cứng khác nhau.
Overfitting / Underfitting	Quá khớp / Chưa khớp (tình trạng ghi nhớ quá mức dữ liệu huấn luyện hoặc chưa đủ khả năng học đặc trưng của mô hình).
Prompt	Gợi ý đầu vào (thông tin dẫn hướng dạng điểm, khung bao hoặc văn bản giúp mô hình phân vùng chính xác).
Stratified Sampling	Lấy mẫu phân tầng (kỹ thuật chia tập dữ liệu đảm bảo tỷ lệ phân phối đồng đều các lớp).
Vision Transformer (ViT)	Kiến trúc Transformer cho thị giác máy tính (học các đặc trưng toàn cục nhờ cơ chế Attention).
VLM (Vision Language Model)	Mô hình thị giác - ngôn ngữ (mô hình đa phương thức xử lý đồng thời cả hình ảnh và chữ viết).
Warmup	Khởi động ấm (tăng dần tốc độ học từ nhỏ đến giá trị mục tiêu trong các epoch đầu tiên).
Weight decay	Suy giảm trọng số (kỹ thuật chính quy hóa giúp kiểm soát độ phức tạp mô hình để ngăn chặn tình trạng quá khớp).
WeightedRandomSampler	Bộ lấy mẫu ngẫu nhiên có trọng số dùng để xử lý sự mất cân bằng giữa các lớp dữ liệu.
Zero-shot	Khả năng suy luận trực tiếp trên miền dữ liệu mới mà không cần huấn luyện bổ sung.

Thông tin nhóm và Phân công công việc

Đồ án được thực hiện với sự phân công vai trò cụ thể qua các giai đoạn từ xử lý dữ liệu, thử nghiệm mô hình, phát triển ứng dụng đến triển khai hệ thống trên Cloud, như được chi tiết tại Bảng 2:

Bảng 2: Bảng phân công công việc chi tiết của các thành viên

Họ và tên	MSSV	Phân công công việc
Nguyễn Hồ Anh Tuấn	23120185	Tiền xử lý & augmentation; Huấn luyện YOLO26-seg; Phát triển Backend FastAPI (ONNX Runtime, DB integration), integration testing; Tổ chức lưu trữ Cloud.
Lê Xuân Trí	23120099	Phân tích EDA dữ liệu; Huấn luyện Mask R-CNN; Xây dựng Expert Knowledge Base, OpenAPI specs; Thiết lập K8s (k3s), CI/CD, Helm Chart, Traefik & DuckDNS.
Đàm Tiến Đạt	23120118	Thu thập & merge dữ liệu; Huấn luyện MobileSAM; Hyperparameter tuning (RayTune/ASHA), push Hugging-Face; Tối ưu YOLO26-seg (ONNX Quantization), setup model serving.
Tổng Thanh Phúc	23120158	Huấn luyện RF-DETR; Thiết kế SQLModel DB, cấu hình MinIO, load testing.
Dương Tuấn Anh	23120208	Huấn luyện Mask2Former; Phát triển Frontend Next.js, storage scaling; Biên tập Video Demo.

1 Giới thiệu

1.1 Phân tích Vấn đề (Problem Definition)

Nông nghiệp luôn đóng vai trò là trụ đỡ quan trọng của nền kinh tế Việt Nam, đóng góp đáng kể vào tổng sản phẩm quốc nội (GDP) và đảm bảo an ninh lương thực quốc gia. Trong số các cây trồng chủ lực, lúa gạo và cà phê Robusta là hai mặt hàng xuất khẩu nông sản hàng đầu, đưa Việt Nam trở thành quốc gia xuất khẩu gạo và cà phê thuộc nhóm lớn nhất thế giới. Các vùng sản xuất lúa trọng điểm tại Đồng bằng sông Cửu Long và các vùng chuyên canh cà phê tại Tây Nguyên là sinh kế của hàng triệu hộ nông dân.

Tuy nhiên, năng suất và chất lượng của hai loại nông sản đặc sản này thường xuyên đối mặt với nguy cơ suy giảm nghiêm trọng do dịch bệnh và sâu hại lá. Sự bùng phát của các loại bệnh như đạo ôn lá, đốm nâu trên cây lúa hay nấm rỉ sắt, đốm rong trên cây cà phê gây thiệt hại to lớn về kinh tế cho người nông dân. Trong canh tác truyền thống, việc phát hiện và chẩn đoán bệnh

chủ yếu dựa vào kinh nghiệm cảm quan của nông hộ. Khi gặp những vết bệnh lạ hoặc ở giai đoạn chớm nở, nông dân thường không thể tiếp cận các chuyên gia bệnh học thực vật kịp thời do sự thiếu hụt nhân lực khuyến nông tại các vùng sâu vùng xa. Hệ quả là nông dân thường chẩn đoán sai bệnh hoặc tự ý phun thuốc bảo vệ thực vật theo kiểu bao vây. Hành vi này không chỉ làm gia tăng chi phí sản xuất, giảm chất lượng nông sản xuất khẩu do tồn dư hóa chất mà còn gây ô nhiễm nguồn nước, suy thoái đất canh tác và ảnh hưởng trực tiếp đến sức khỏe con người.

Từ bối cảnh thực tiễn cấp thiết trên, việc nghiên cứu và ứng dụng công nghệ học máy để tự động nhận diện và chẩn đoán bệnh trên lá cây trực tiếp ngoài đồng ruộng là một hướng đi vô cùng ý nghĩa. Một hệ thống AI có khả năng hoạt động ổn định trên các thiết bị di động bình dân sẽ cung cấp cho người nông dân một công cụ chẩn đoán nhanh, nhất quán và đáng tin cậy. Về mặt toán học, bài toán chẩn đoán vết bệnh trên lá cây được định nghĩa như một tác vụ phân vùng thực thể (instance segmentation). Cho ảnh đầu vào $I \in \mathbb{R}^{H \times W \times 3}$, trong đó H và W lần lượt là chiều cao và chiều rộng của ảnh. Hệ thống cần tìm tập hợp gồm K thực thể bệnh xuất hiện trong ảnh:

$$E = \{e_1, e_2, \dots, e_K\}. \quad (1)$$

Trong đó, mỗi thực thể vết bệnh e_k ($k \in \{1, 2, \dots, K\}$) được biểu diễn bằng một bộ ba:

$$e_k = (b_k, c_k, m_k), \quad (2)$$

Với:

- $b_k = [x_{min}, y_{min}, x_{max}, y_{max}] \in \mathbb{R}^4$ là tọa độ của hộp bao (bounding box) giới hạn thực thể e_k .
- $c_k \in \{1, 2, \dots, C\}$ là nhãn lớp bệnh tương ứng với thực thể e_k trong tập C lớp nhãn mục tiêu ($C = 4$ cho từng miền dữ liệu cây trồng).
- $m_k \in \{0, 1\}^{H \times W}$ là mặt nạ nhị phân (binary mask) xác định vùng bị tổn thương ở cấp độ điểm ảnh (pixel-level) của thực thể e_k .

Việc lựa chọn hướng phân vùng thực thể thay vì chỉ phân loại ảnh (image classification) xuất phát từ các đặc tính thực tế của ảnh chụp ngoài đồng ruộng:

- Ảnh chụp thực tế thường chứa nhiều lá cây nằm chồng chéo lên nhau hoặc một lá cây có thể xuất hiện đồng thời nhiều loại bệnh khác nhau. Phân vùng thực thể cho phép khoanh vùng và chẩn đoán từng vết bệnh riêng biệt trên từng chiếc lá.

- Vết bệnh thường chỉ chiếm một tỷ lệ diện tích rất nhỏ so với diện tích lá lành và bối cảnh nền. Việc chỉ phân loại ảnh dễ bị nhiễu do bối cảnh nền phức tạp ngoài tự nhiên.
- Cung cấp cho nông dân hình ảnh trực quan sinh động về vị trí và diện tích chính xác của các vết bệnh trên lá cây để họ dễ dàng đánh giá mức độ nghiêm trọng của dịch bệnh.

Hệ thống chẩn đoán thực tế phải đối mặt với nhiều thách thức kỹ thuật lớn:

- Sự tương đồng về mặt hình thái học giữa một số cặp bệnh ở giai đoạn sớm (ví dụ: đốm nâu và đạo ôn trên lúa, đốm rong và gỉ sắt trên cà phê) làm giảm khả năng phân biệt nếu chỉ dựa trên đặc trưng màu sắc.
- Sự biến thiên mạnh mẽ về điều kiện ánh sáng tự nhiên (nắng gắt, bóng râm, ngược sáng), góc chụp và độ mờ do camera điện thoại bình dân của người nông dân.
- Mất cân bằng dữ liệu nghiêm trọng giữa các lớp bệnh phổ biến (như bệnh gỉ sắt chiếm đa số) và các lớp bệnh hiếm gặp hơn (như phấn trắng).

1.2 Mục tiêu của Đề án


Đề án hướng tới việc giải quyết toàn diện bài toán chẩn đoán bệnh trên lá cây đặc sản thông qua các mục tiêu cụ thể sau:

- Xây dựng và chuẩn hóa một bộ dữ liệu thực địa gồm 7.149 ảnh sạch gắn nhãn chất lượng cao cho 8 lớp mục tiêu (Healthy, BrownSpot, Hispa, LeafBlast đối với lúa; LeafMiner, PowderyMildew, Rust, AlgalLeafSpot đối với cà phê).
- Nghiên cứu, huấn luyện và đánh giá so sánh hiệu năng của 5 mô hình phân vùng thực thể hiện đại (Mask R-CNN, YOLO26m-seg, RF-DETR, MobileSAM, Mask2Former) trên tập dữ liệu đã xây dựng.
- Tinh chỉnh tối ưu hóa siêu tham số bằng thuật toán tìm kiếm thông minh Ray Tune và bộ lập lịch ASHA để nâng cao chất lượng dự đoán của mô hình tốt nhất, hướng tới vượt qua các mô hình SOTA (State-of-the-Art) trên tập kiểm thử tĩnh.
- Phát triển ứng dụng Web hoàn chỉnh tích hợp mô hình đã được tối ưu hóa (ONNX Runtime, FastAPI, Next.js) đạt độ trễ suy luận dưới 200 ms/ảnh để phục vụ người dùng thời gian thực.

- Triển khai ứng dụng lên nền tảng đám mây công khai sử dụng cụm Kubernetes (k3s) trên GCP, cấu hình tên miền động DuckDNS và mã hóa SSL bảo mật, đi kèm quy trình tự động hóa CI/CD.

1.3 Tổng quan về Phương pháp

Để đạt được các mục tiêu trên, nhóm đề xuất một quy trình xây dựng hệ thống gồm 3 giai đoạn chính được minh họa trong Hình 1:



Hình 1: Sơ đồ quy trình tổng thể 9 bước của hệ thống chẩn đoán bệnh cây trồng

Quy trình 9 bước bao gồm các nội dung chính sau:


- Pha 1 (Các bước 1, 2, 3): Thu thập dữ liệu từ các nguồn mở bản địa sử dụng công cụ cào tự động Crawl4AI kết hợp tiền gán nhãn bằng mô hình ngôn ngữ lớn thị giác Gemma 4. Tiến hành kiểm duyệt thủ công bằng Streamlit Labeler (quy trình human-in-the-loop) và tạo pseudo-mask bằng SAM 3. Dữ liệu được chia tập Train/Val/Test theo tỷ lệ 70/15/15 phân tầng (stratified split) để chống rò rỉ dữ liệu.
- Pha 2 (Các bước 4, 5, 6): Huấn luyện độc lập 5 mô hình (Mask R-CNN, YOLO26m-seg, RF-DETR, MobileSAM, Mask2Former) trên GPU T4 của Kaggle. Lựa chọn mô hình YOLO26m-seg và tinh chỉnh siêu tham số bằng Ray Tune + ASHA, sau đó thực hiện lượng tử hóa sang định dạng ONNX phục vụ tối ưu hóa suy luận CPU.

- Pha 3 (Các bước 7, 8, 9): Phát triển backend FastAPI kết nối PostgreSQL (lưu lịch sử), MinIO (lưu ảnh) và Redis (caching). Xây dựng frontend bằng Next.js tạo giao diện trực quan. Toàn bộ hệ thống được container hóa bằng Docker, quản lý bởi Helm Chart và triển khai lên cụm Kubernetes k3s trên GCP.

2 Thu thập và phân tích dữ liệu

2.1 Nguồn và phương pháp thu thập

Nhóm đã mở rộng hai bộ dataset có sẵn là [Rice Diseases Image Dataset](#) và [Detect Disease On Coffee Leaves](#) bằng cách thu thập thêm ảnh từ các trang web, blog. Hình 2 thể hiện quy trình thu thập. Quy trình này được thiết kế chặt chẽ nhằm đảm bảo tính đa dạng về điều kiện chiếu sáng, góc chụp đồng thời giúp thời gian gắn nhãn.



Hình 2: Sơ đồ pipeline thu thập và gán nhãn dữ liệu theo hướng human-in-the-loop.

Tập dữ liệu thu thập được bao gồm 7.300 ảnh chuẩn hóa định dạng COCO với tổng cộng 7.562 thực thể vết bệnh được gán nhãn phục vụ cho bài toán segmentation, được phân chia thành hai miền dữ liệu chính. Miền dữ liệu lúa bao gồm 3.421 ảnh và 3.720 annotation với bốn lớp nhãn chính: lá khỏe mạnh, bệnh đạo ôn, bệnh sâu đục lá và bệnh đốm nâu. Miền dữ liệu cà phê bao gồm 3.879 ảnh và 3.842 annotation với bốn lớp nhãn chính: bệnh rỉ sắt, bệnh sâu đục lá, bệnh đốm rong và bệnh phấn trắng.

2.2 Tiền xử lý và làm sạch

Dữ liệu thô thu thập từ nhiều nguồn thường chứa các ảnh mờ nhòe hay ảnh trùng lặp. Nhóm đã áp dụng quy trình kiểm duyệt chất lượng nghiêm ngặt gồm hai bước. Bước đầu tiên là khử trùng lặp thông qua việc tính toán hàm băm MD5 trên nội dung nhị phân của ảnh để phát hiện và loại bỏ chính xác các ảnh trùng lặp hoàn toàn. Bước thứ hai là lọc ảnh mờ nhòe bằng phương pháp đánh giá độ sắc nét dựa trên phương sai của phép biến đổi Laplacian, trong đó các ảnh có phương sai dưới ngưỡng $\tau = 100$ được loại bỏ khỏi tập dữ liệu sạch.

Kết quả tổng hợp quy trình làm sạch dữ liệu trên toàn bộ tập ảnh được thể hiện chi tiết tại Bảng 3.

Bảng 3: Tổng hợp kết quả làm sạch dữ liệu trên toàn bộ tập ảnh

Lý do xử lý	Số lượng ảnh	Tỷ lệ (%)
Ảnh trùng lặp	1	0,01
Ảnh mờ nhòe	150	2,05
Giữ lại sử dụng	7.149	97,93

Sau khi loại bỏ 151 ảnh nhiễu, tập dữ liệu sạch giữ lại 7.149 ảnh (chiếm 97,93%) với 7.411 annotation hợp lệ. Phân bố chi tiết số lượng ảnh và tỷ lệ tương ứng theo từng lớp bệnh ở hai miền dữ liệu sau bước làm sạch được thống kê tại Bảng 4.

Bảng 4: Phân bố chi tiết số ảnh theo lớp và miền dữ liệu sau làm sạch

Miền dữ liệu	Lớp bệnh	Số lượng ảnh	Tỷ lệ trong miền (%)
Lúa (3.351 ảnh)	Lá khỏe mạnh	1.472	43,93
	Bệnh đạo ôn	777	23,19
	Sâu đục lá	571	17,04
	Bệnh đốm nâu	531	15,85
Cà phê (3.798 ảnh)	Bệnh rỉ sắt	1.387	36,52
	Sâu đục lá	1.200	31,60
	Bệnh đốm rong	949	24,99
	Bệnh phấn trắng	262	6,90


2.3 Phân tích và khám phá dữ liệu

Để hiểu rõ đặc trưng phân bố và định hướng thiết kế mô hình, nhóm thực hiện phân tích khám phá dữ liệu trên tập thu thập theo năm khía cạnh: mất cân bằng lớp, hình học ảnh, mẫu bệnh

trực quan, độ sáng - màu sắc, và cấu trúc annotation COCO.

2.3.1 Phân bố lớp và mức độ mất cân bằng

Hình 3 thể hiện phân bố tuyệt đối và tỉ lệ phần trăm theo từng lớp bệnh. Hai chỉ số được dùng để định lượng mất cân bằng là tỉ số mất cân bằng $IR = N_{\max}/N_{\min}$ và hệ số biến thiên $CV = \sigma_N/\mu_N$. Miền lúa có $IR = 2,77$ và $CV = 52,1\%$ (lớp đa số là lá khỏe mạnh, lớp thiểu số là đốm nâu). Miền cà phê lệch mạnh hơn với $IR = 5,28$ và $CV = 51,8\%$ do lớp phần trắng chỉ chiếm khoảng 6,9% ảnh trong miền. Sau bước làm sạch (Bảng 4), tỉ lệ tương đối giữa các lớp gần như không đổi, nên mất cân bằng vẫn là ràng buộc chính khi huấn luyện và đòi hỏi hàm mất mát có trọng số cùng tăng cường dữ liệu cho lớp thiểu số.




Hình 3: Phân bố số lượng ảnh và tỉ lệ phần trăm theo lớp bệnh trên hai miền lúa và cà phê.

2.3.2 Độ phân giải, tỉ lệ khung hình và annotation

Hình 4 cho thấy sự chênh lệch lớn về kích thước giữa hai miền. Ảnh lúa có độ phân giải trung bình khoảng 2.031×2.026 px, chủ yếu vuông, với khoảng biến thiên rộng từ khoảng 132 đến 3.120 px theo chiều rộng. Ảnh cà phê nhỏ hơn rõ rệt (trung bình khoảng 971×1.154 px) và thiên về khung hình dọc. Do đó, đầu vào mô hình cần được chuẩn hóa về cùng kích thước (640×640

hoặc 256×256 tùy kiến trúc) bằng letterbox để giữ tỉ lệ thật của lá và tránh méo dạng vùng bệnh.




Hình 4: Phân tích kích thước ảnh: quan hệ width-height, phân phối chiều rộng và tỉ lệ khung hình theo miền dữ liệu.

Song song đó, Hình 5 phân tích cấu trúc nhãn COCO. Số annotation trên mỗi ảnh lúa trung bình đạt 1,09 (dao động từ 1 đến tối đa 28), trong khi miền cà phê gần như luôn có đúng một thực thể trên mỗi ảnh. Tỉ lệ diện tích bounding box so với ảnh ở lúa thường cao hơn cà phê, cho thấy vùng quan tâm chiếm phần lớn khung hình. Các quan sát này hỗ trợ chiến lược huấn luyện trên ảnh toàn phần kèm tăng cường theo tỉ lệ và vị trí vùng bệnh.

2.3.3 Trực quan hóa mẫu bệnh

Hình 6 và Hình 7 minh họa một số mẫu ngẫu nhiên theo từng lớp. Quan sát trực quan cho thấy các lớp có triệu chứng gần nhau (đốm nâu và đạo ôn trên lúa; đốm rong và rỉ sắt trên cà phê), đồng thời tồn tại ảnh nhiều thực địa như góc chụp xa, nhiều lá chồng nhau hoặc bệnh ở giai đoạn sớm. Những trường hợp này giải thích vì sao đặc trưng màu toàn cục không đủ để tách lớp và cần mô hình học kết cấu cục bộ cùng ngữ cảnh không gian.




Hình 5: Phân tích annotation COCO: số thực thể trên mỗi ảnh, tỉ lệ diện tích bounding box và phân phối kích thước vùng bệnh.

2.3.4 Độ sáng, kênh màu và cặp bệnh dễ nhầm lẫn

Hình 8 so sánh độ sáng cảm nhận, giá trị trung bình các kênh RGB và độ tương phản theo lớp. Ảnh lúa nhìn chung sáng hơn rõ rệt (độ sáng trung bình khoảng 198-202) so với cà phê (khoảng 116-129). Ở cả hai miền, kênh Green thường chiếm ưu thế, phù hợp đặc trưng sắc tố lá; tuy nhiên biên độ và độ tương phản giữa các lớp vẫn giao thoa đáng kể. Vì vậy, tiền xử lý cần chuẩn hóa theo thống kê tập huấn luyện và dùng tăng cường biến thiên độ sáng để tăng độ bền với điều kiện chiếu sáng thực địa.

Để định lượng mức độ tương đồng màu giữa các cặp dễ nhầm, Hình 9 đối chiếu histogram chuẩn hóa ba kênh RGB thông qua khoảng cách Bhattacharyya D_B . Trên lúa, cặp đốm nâu và đạo ôn có D_B nhỏ trên cả ba kênh (lớn nhất ở kênh Red với $D_B = 0,132$). Trên cà phê, cặp đốm rong và rỉ sắt gần như trùng khớp hoàn toàn ($D_B \approx 0,003-0,005$). Kết quả này khẳng định mô hình không thể dựa chủ yếu vào phân bố màu toàn cục mà cần học đặc trưng kết cấu và hình thái vùng bệnh.

Mẫu ảnh bệnh lá Lúa — 4 lớp × 4 mẫu




Hình 6: Một số mẫu ảnh tiêu biểu theo từng lớp bệnh trên miền lúa.


Mẫu ảnh bệnh lá Cà phê — 4 lớp × 4 mẫu



Hình 7: Một số mẫu ảnh tiêu biểu theo từng lớp bệnh trên miền cà phê.



Hình 8: Phân phối độ sáng, giá trị trung bình kênh RGB và độ tương phản theo lớp bệnh trên hai miền dữ liệu.



Hình 9: So sánh histogram RGB và khoảng cách Bhattacharyya giữa các cặp bệnh dễ nhầm lẫn trên lúa và cà phê.

3 Lựa chọn và Huấn luyện Mô hình

3.1 Chuẩn bị Dữ liệu cho Mô hình

Trước khi đưa vào huấn luyện, tập dữ liệu sạch gồm 7.149 ảnh được phân chia thành ba tập đào tạo, thẩm định và kiểm thử theo tỷ lệ chuẩn 70 : 15 : 15. Để đảm bảo tính khách quan và ngăn chặn tuyệt đối hiện tượng rò rỉ dữ liệu, nhóm áp dụng kỹ thuật Stratified Sampling đảm bảo tỷ lệ các lớp.

Chi tiết phân bố số lượng ảnh theo từng tập con và lớp bệnh được tổng hợp tại Bảng 5.

Bảng 5: Phân bố số lượng ảnh theo tập con, miền và lớp bệnh

Miền dữ liệu	Lớp bệnh	Train (70%)	Val (15%)	Test (15%)	Tổng cộng
Lúa	Lá khỏe mạnh	1.030	221	221	1.472
	Bệnh đạo ôn	544	116	117	777
	Sâu đục lá	400	85	86	571
	Bệnh đốm nâu	372	80	79	531
Cà phê	Bệnh rỉ sắt	971	208	208	1.387
	Sâu đục lá	840	180	180	1.200
	Bệnh đốm rong	664	142	143	949
	Bệnh phấn trắng	183	40	39	262
Tổng toàn cục	8 lớp bệnh	5.004	1.072	1.073	7.149

Để tăng khả năng tổng quát hóa, nhóm đã sử dụng kỹ thuật tăng cường dữ liệu. Các phép biến đổi hình thái và màu sắc được áp dụng ngẫu nhiên trong quá trình huấn luyện. Cụ thể như sau: cắt và thay đổi kích thước ngẫu nhiên (tỷ lệ 0,75 đến 1,0), lật ngang với xác suất $p = 0,5$, lật dọc với $p = 0,2$, biến đổi affine xoay $\pm 30^\circ$, điều chỉnh màu sắc và trộn ảnh ngẫu nhiên với hệ số $\alpha = 0,4$.

3.2 Lựa chọn và Kiến trúc Mô hình

Để giải quyết trọn vẹn bài toán phân vùng thực thể lá cây bị bệnh với hai mục tiêu song hành là độ chính xác cao và tốc độ suy luận nhanh đáp ứng triển khai thực tế, nhóm đã khảo sát, huấn luyện và so sánh năm kiến trúc tiên tiến thuộc hai trường phái mạng nơ-ron tích chập (CNN) và mạng thị giác sử dụng cơ chế chú ý (Vision Transformer) (được tổng hợp tại Bảng 6).

Sau khi khảo sát, nhóm lựa chọn mô hình YOLO26-seg làm mô hình hạt nhân cho việc lượng tử hóa và triển khai thực tế. Mô hình sử dụng mạng tích chập sâu với cấu trúc phân tầng gồm

Bảng 6: Tổng quan và đặc điểm của năm mô hình segmentation được thử nghiệm

Mô hình	Họ kiến trúc	Đặc điểm nổi bật và lý do lựa chọn
Mask R-CNN [3]	CNN	Kiến trúc hai giai đoạn kinh điển, mang lại độ chính xác cao trong phân vùng thực thể. Được chọn làm baseline để đánh giá và đối chiếu hiệu suất.
YOLO26m-seg [5, 4]	CNN	Kiến trúc một giai đoạn với tốc độ suy luận thời gian thực xuất sắc. Phiên bản cỡ medium được chọn nhằm tối ưu hóa điểm cân bằng giữa độ chính xác và tốc độ trong thực tế.
RF-DETR [10, 8]	ViT	Thiết kế end-to-end loại bỏ hoàn toàn bước hậu xử lý NMS, sử dụng DINOv2 feature extractor để tận dụng khả năng zero-shot và hiệu suất học ngữ cảnh mạnh mẽ. Được chọn làm đại diện cho dòng mô hình Transformer-based tốc độ cao.
MobileSAM [15, 14]	ViT	Phiên bản thu gọn siêu nhẹ của Segment Anything Model (SAM). Được chọn nhờ khả năng zero-shot linh hoạt với prompt và tối ưu hóa chuyên sâu để triển khai trên edge devices.
Mask2Former [2]	ViT	Kiến trúc phân vùng hợp nhất dựa trên mask classification. Được chọn nhờ đạt hiệu năng đa tác vụ vượt trội (panoptic, instance, semantic).

ba khối chức năng chính:

- **Backbone (Xương sống):** Sử dụng các khối liên kết cào đặc trưng cải tiến (C2f) và Spatial Pyramid Pooling Fast (SPPF) nhằm trích xuất đa quy mô các đặc trưng ngữ cảnh từ hình ảnh lá cây bị bệnh.
- **Neck (Cổ mạng):** Sử dụng cấu trúc mạng kim tự tháp đặc trưng hai chiều (PANet) kết hợp luồng thông tin từ dưới lên và từ trên xuống để tổng hợp các đặc trưng ngữ cảnh không gian và thông tin ngữ nghĩa cấp cao.
- **Head (Đầu dự đoán phân vùng):** Áp dụng kiến trúc Anchor-free dự đoán song song hai nhánh độc lập (Decoupled Head) bao gồm: một nhánh dự đoán hộp bao kèm nhãn bệnh lớp mục tiêu, và một nhánh dự đoán tập hợp các mặt nạ nguyên mẫu (Prototype Masks) kết hợp với các hệ số mặt nạ (Mask Coefficients) để tạo ra mặt nạ phân vùng thực thể cuối cùng ở cấp độ điểm ảnh.

3.3 Cấu hình Huấn luyện

Toàn bộ quá trình huấn luyện các mô hình được thực hiện trên GPU NVIDIA Tesla T4. Cấu hình huấn luyện chung và tham số riêng cho từng mô hình được tổng hợp tại Bảng 7 và Bảng 8. Đối với mô hình YOLO26-seg, hàm mất mát toàn cục $\mathcal{L}_{total}$ được định nghĩa là sự kết hợp tuyến tính có trọng số của các hàm mất mát thành phần:

$$\mathcal{L}_{total} = \lambda_{box}\mathcal{L}_{box} + \lambda_{cls}\mathcal{L}_{cls} + \lambda_{dfl}\mathcal{L}_{dfl} + \lambda_{mask}\mathcal{L}_{mask}, \quad (3)$$

Trong đó:

- $\mathcal{L}_{box}$ là hàm mất mát Complete Intersection over Union (CIoU) đo lường độ sai lệch về kích thước, tỷ lệ khung hình và vị trí tâm của hộp bao dự đoán so với nhãn thực tế.
- $\mathcal{L}_{cls}$ là hàm mất mát entropy chéo nhị phân (Binary Cross Entropy - BCE) để phân loại nhãn lớp vết bệnh cho các hộp bao.
- $\mathcal{L}_{dfl}$ là hàm mất mát phân bố tiêu điểm (Distribution Focal Loss) hỗ trợ việc tinh chỉnh biên hộp bao tốt hơn trong các trường hợp ranh giới mờ nhòe.
- $\mathcal{L}_{mask}$ là hàm mất mát nhị phân kết hợp cấp độ điểm ảnh (gồm BCE loss và Dice loss) nhằm tối ưu hóa độ trùng khớp hình thái của mặt nạ phân vùng.

Bảng 7: Thiết lập cấu hình huấn luyện chung cho năm mô hình

Tham số	Giá trị thiết lập
GPU	NVIDIA Tesla T4
Tỷ lệ chia dữ liệu	70 : 15 : 15
Thuật toán tối ưu	AdamW
Effective batch size	8
Số Epoch tối đa	30
Dừng sớm	5
Seed	3407

3.4 Tinh chỉnh siêu tham số

Sau khi so sánh 5 mô hình và chọn ra mô hình tốt nhất, nhóm áp dụng phương pháp tinh chỉnh siêu tham số của mô hình YOLO26m-seg một cách tự động bằng thư viện Ray Tune [7] với

Bảng 8: Cấu hình tham số riêng theo yêu cầu kiến trúc từng mô hình

Mô hình	Learning Rate khởi tạo	Kích thước ảnh	Ghi chú kỹ thuật
Mask R-CNN	1×10^{-4}	256×256	Batch size 2, gradient accumulation 4
YOLO26m-seg	8×10^{-4}	640×640	Batch size 8
RF-DETR	1×10^{-4}	640×640	Batch size 2, gradient accumulation 4
MobileSAM	1×10^{-5}	1024×1024	Batch size 2, gradient accumulation 4
Mask2Former	5×10^{-5}	384×384	Batch size 4, gradient accumulation 2

thuật toán lập lịch bất đồng bộ ASHA. Thuật toán này cho phép đánh giá song song nhiều cấu hình thử nghiệm và sớm loại bỏ các cấu hình kém hiệu quả ngay từ những epoch đầu, giúp tiết kiệm đáng kể tài nguyên tính toán.

Quá trình tìm kiếm được thực hiện với 20 thử nghiệm độc lập trên không gian sáu siêu tham số, được chi tiết hóa tại Bảng 9.

Bảng 9: Không gian tìm kiếm siêu tham số cho YOLO26m-seg bằng Ray Tune

Siêu tham số	Kiểu phân phối tìm kiếm	Khoảng giá trị hoặc tập lựa chọn
Learning rate ban đầu (lr_0)	Log-uniform	$[1 \times 10^{-5}, 1 \times 10^{-2}]$
Momentum	Uniform	$[0, 85, 0, 95]$
Weight decay	Log-uniform	$[1 \times 10^{-5}, 1 \times 10^{-3}]$
Warmup epochs	Choice	$\{1, 2, 3\}$
Hệ số mất mát khung bao (λ_{box})	Uniform	$[5, 0, 10, 0]$
Hệ số mất mát phân loại (λ_{cls})	Uniform	$[0, 3, 0, 8]$

4 Kết quả và Thảo luận

4.1 Kết quả Thử nghiệm

Trong phần này, chúng tôi trình bày kết quả đánh giá hiệu năng của 5 mô hình phân vùng thực thể (MobileSAM, YOLO26-seg, RF-DETR, Mask R-CNN, Mask2Former) trên tập dữ liệu kiểm thử (Test set) của hai miền dữ liệu lúa và cà phê. Các chỉ số được sử dụng để đánh giá bao gồm mAP@50, mAP@50:95 (đối với mask), mIoU, và hệ số Dice. Ngoài ra, tốc độ suy luận (Inference time) tính bằng mili-giây (ms) và kích thước mô hình (Size) tính bằng MB cũng được đo lường để đánh giá khả năng triển khai thực tế.

Bảng 10 và Bảng 11 tóm tắt các chỉ số trên tập kiểm thử của hai loại cây trồng.


Bảng 10: So sánh hiệu năng của các mô hình trên tập dữ liệu Lúa (Rice)

Mô hình	mAP@50	mAP@50:95	mIoU	Dice	Inference (ms)	Size (MB)
MobileSAM	0.5637	0.5141	0.5440	0.5712	1487.54	41.30
Mask R-CNN	0.5966	0.5294	0.8669	0.8935	760.50	503.44
Mask2Former	0.6971	0.6762	0.6507	0.6618	96.81	181.07
RF-DETR	0.7038	0.6874	0.8132	0.8308	198.31	127.10
YOLO26-seg	0.8247	0.7891	0.8543	0.8712	65.72	6.23

Bảng 11: So sánh hiệu năng của các mô hình trên tập dữ liệu Cà phê (Coffee)

Mô hình	mAP@50	mAP@50:95	mIoU	Dice	Inference (ms)	Size (MB)
MobileSAM	0.6923	0.6591	0.6671	0.6848	1616.84	41.30
RF-DETR	0.8428	0.8251	0.8575	0.8718	70.31	127.10
YOLO26-seg	0.9012	0.8637	0.8921	0.9087	20.21	6.23
Mask2Former	0.9200	0.8998	0.8870	0.8999	62.88	181.07
Mask R-CNN	0.9480	0.9041	0.9128	0.9356	702.36	501.73

Nhìn chung, Mask R-CNN và Mask2Former cho độ chính xác rất cao trên tập Cà phê nhưng lại có dấu hiệu kém ổn định hơn trên tập Lúa (đặc biệt là Mask R-CNN ở chỉ số mAP). YOLO26-seg thể hiện sự cân bằng tốt khi đứng đầu về mAP trên tập Lúa và đứng thứ ba với khoảng cách rất nhỏ trên tập Cà phê, trong khi sở hữu tốc độ suy luận cực nhanh và kích thước gọn nhẹ. Để thấy rõ hơn quá trình hội tụ, Hình 10 thể hiện đường cong học tập (learning curves) của mô hình YOLO26-seg trên hai tập dữ liệu.



Hình 10: Đường cong học tập (Loss và mAP) của YOLO26-seg qua các vòng lặp (epochs)

Từ biểu đồ, có thể thấy hàm mất mát (loss) giảm ổn định và các chỉ số mAP tăng nhanh chóng trong khoảng 30 epochs đầu tiên. Sau epoch thứ 40, đồ thị dần đi vào trạng thái bão hòa và hội tụ tốt tại epoch thứ 50 mà không có dấu hiệu bị nhiễu động mạnh, chứng tỏ quá trình huấn luyện đã thiết lập được các siêu tham số học tập (learning rate) phù hợp.

4.2 So sánh và Thảo luận

4.2.1 Đánh giá Trade-off và Lựa chọn Mô hình

Mặc dù Mask R-CNN đạt chỉ số mAP cao nhất trên tập Cà phê (0.9480), nhưng kích thước mô hình lên tới 503 MB và thời gian suy luận hơn 700 ms trên CPU khiến việc triển khai trực tiếp lên ứng dụng web thời gian thực là không khả thi. MobileSAM có kích thước gọn hơn (41.3 MB) nhưng lại rất chậm (hơn 1400 ms) do kiến trúc phức tạp của mô hình nền tảng.

YOLO26-seg nổi bật như một ứng cử viên xuất sắc nhất khi đạt mAP@50 0.8247 (Lúa) và 0.9012 (Cà phê), xếp sau Mask R-CNN trên tập Cà phê nhưng nhanh hơn gấp 35 lần (20.21 ms) và kích thước siêu nhỏ (6.23 MB). Nhờ khả năng suy luận theo thời gian thực và tiêu thụ rất ít tài nguyên, YOLO26-seg đã được nhóm chọn làm mô hình chính thức để triển khai.

4.2.2 Cải thiện với RayTune và ASHA

Để tối ưu hóa thêm cho mô hình YOLO26-seg, chúng tôi đã sử dụng thuật toán RayTune kết hợp với bộ lập lịch ASHA để tìm kiếm siêu tham số. Kết quả so sánh hiệu năng của mô hình trước và sau khi tinh chỉnh được tổng hợp trong Bảng 12.


Bảng 12: Kết quả của YOLO26-seg trước và sau khi tinh chỉnh bằng RayTune

Tập dữ liệu	Trạng thái	mAP@50	mAP@50:95	mIoU	Dice	Inference (ms)	Size (MB)
Lúa (Rice)	Baseline	0.8247	0.7891	0.8543	0.8712	65.72	6.23
	Tuned	0.8481	0.8034	0.8697	0.8856	65.41	6.23
Cà phê (Coffee)	Baseline	0.9012	0.8637	0.8921	0.9087	20.21	6.23
	Tuned	0.9234	0.8845	0.9053	0.9192	19.85	6.23


Việc tinh chỉnh siêu tham số đã giúp tăng mAP@50 thêm hơn 2% cho cả hai tập dữ liệu, khẳng định tính hiệu quả của phương pháp tìm kiếm tự động kết hợp loại bỏ sớm (early stopping) của thuật toán ASHA.

4.2.3 Phân tích Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn chuẩn hóa của mô hình YOLO26-seg được trình bày tại Hình 11.



(a) Tập dữ liệu Lúa (Rice)



(b) Tập dữ liệu Cà phê (Coffee)

Hình 11: Ma trận nhầm lẫn (Confusion Matrix) của mô hình YOLO26-seg

Dựa trên ma trận nhầm lẫn, có thể thấy một số nhãn có tỷ lệ đoán sai đáng chú ý (confusion pairs):

- Đối với tập dữ liệu Lúa: Mô hình dễ nhầm lẫn giữa bệnh đốm nâu (BrownSpot) và bộ xít gai (Hispa), hoặc giữa BrownSpot và LeafBlast. Nguyên nhân chủ yếu xuất phát từ sự tương đồng hình thái ở giai đoạn đầu của bệnh, khi cả ba vết bệnh đều biểu hiện dưới dạng các chấm nhỏ li ti màu nâu nhạt trên bề mặt lá.
- Đối với tập dữ liệu Cà phê: Mô hình đôi khi nhầm lẫn giữa bệnh rỉ sắt (Rust) và đốm rong (AlgalLeafSpot). Cả hai loại bệnh này đều có xu hướng gây ra những vùng đốm tròn màu vàng hoặc gỉ sắt ở mặt dưới lá, gây khó khăn cho việc phân loại chính xác khi ảnh chụp không đủ độ phân giải hoặc bị ngược sáng.

4.2.4 Hiện tượng Overfitting và Underfitting

Qua các biểu đồ và chỉ số, chúng tôi ghi nhận một số vấn đề liên quan đến hiện tượng khớp quá mức (overfitting) và chưa khớp (underfitting):

- Hiện tượng chưa khớp (underfitting) xảy ra với MobileSAM khi mô hình đạt mAP thấp nhất trên tập Lúa (0.5637). Do kiến trúc là Zero-shot segmentation được fine-tune, mô hình khó nắm bắt các chi tiết cực kỳ nhỏ gọn như vết bệnh Hispa trên lá lúa. Biện pháp khắc phục là sử dụng mô hình chuyên biệt (như YOLO) kết hợp với các anchor box phù hợp với đối tượng kích thước nhỏ.
- Hiện tượng khớp quá mức (overfitting) xuất hiện ở Mask R-CNN và Mask2Former do cả hai mô hình này đều có kích thước tham số rất lớn. Khi thực hiện tinh chỉnh (RayTune)

hoặc áp dụng các augment mạnh hơn, kết quả đánh giá trên tập test thậm chí còn giảm sâu so với baseline (mAP của Mask2Former giảm từ 0.69 xuống 0.10 khi tăng size backbone). Điều này minh chứng cho việc các kiến trúc khổng lồ dễ dàng "ghi nhớ" tập dữ liệu huấn luyện nhỏ. Để khắc phục, cần thu thập thêm dữ liệu (thực tế hoặc qua các phương pháp sinh ảnh), áp dụng thêm cơ chế regularization mạnh (Dropout/Weight decay) và Early Stopping nghiêm ngặt hơn.

5 Xây dựng và Triển khai Ứng dụng

Nhóm tích hợp mô hình YOLO26-seg đã lượng tử hóa vào ứng dụng Web cho phép tải hoặc chụp ảnh lá lúa, cà phê, nhận kết quả dự đoán và tham khảo hướng xử lý bệnh. Hệ thống được triển khai công khai tại <https://plant-disease-demo.duckdns.org/> trên máy ảo Google Cloud Platform (GCP), sử dụng k3s để điều phối các dịch vụ.

5.1 Kiến trúc Hệ thống


Hệ thống tách giao diện, nghiệp vụ, suy luận và lưu trữ thành các tầng độc lập. Người dùng truy cập Next.js qua Traefik; frontend gọi REST API FastAPI tại tiền tố `/api/v1`; backend điều phối ONNX Runtime, cơ sở tri thức, PostgreSQL và MinIO như được mô tả trong Bảng 13. Các dịch vụ dữ liệu chỉ dùng ClusterIP và không mở trực tiếp ra Internet. Hình 12 thể hiện cả luồng truy cập, workload trong k3s và đường triển khai từ GitHub Actions.

Bảng 13: Các thành phần chính trong kiến trúc ứng dụng

Thành phần	Công nghệ	Vai trò
Giao diện	Next.js 15, React 19	Tải/chụp ảnh, xác thực, hiển thị kết quả, lịch sử và cơ sở tri thức.
API và suy luận	FastAPI, ONNX Runtime	Kiểm tra yêu cầu, chạy <code>yolo26_quantized.onnx</code> và bổ sung khuyến nghị.
Dữ liệu	PostgreSQL 16, MinIO	Lưu tài khoản, lịch sử, metadata dự đoán và ảnh người dùng.
Tri thức	JSON theo luật	Ánh xạ tám nhãn sang mô tả, triệu chứng, xử lý và phòng bệnh tiếng Việt.
Điều phối	k3s, Helm, Traefik	Quản lý workload, volume, định tuyến và HTTPS.

Luồng chẩn đoán gồm năm bước: **(1)** frontend gửi ảnh JPEG, PNG hoặc WebP tối đa 10 MB đến `POST /api/v1/predict`; **(2)** backend tiền xử lý ảnh 640×640 và gọi phiên ONNX được lưu trong bộ nhớ tiến trình; **(3)** mô hình trả top-5, nhãn đứng đầu và độ trễ; **(4)** nhãn được

KIẾN TRÚC TRIỂN KHAI GCP / k3s



Hình 12: Kiến trúc triển khai ứng dụng trên GCP và k3s

ảnh xạ sang khuyến nghị chuyên gia, đồng thời ảnh được lưu ở MinIO và metadata được ghi vào PostgreSQL; (5) frontend nhận kết quả, URL ảnh và cảnh báo chụp lại nếu độ tin cậy dưới 60%. Bản ghi được gắn với `user_id` khi người dùng đã đăng nhập.


5.2 Đóng gói và Tích hợp Mô hình

Checkpoint được lượng tử hóa thành `models/yolo26_quantized.onnx` và phục vụ bằng ONNX Runtime [9] trên CPU. Backend đọc tên lớp từ `/models/class_names.json`, nhận đường dẫn qua `MODEL_PATH` và lưu phiên bản `yolo26-seg-onnx` cùng mỗi kết quả. Trên Kubernetes, thư mục `/models` gắn với PVC 10 GiB; init container kiểm tra artifact, tải từ `MODEL_DOWNLOAD_URL` nếu được cấu hình hoặc yêu cầu nạp thủ công. Việc tách model khỏi image giúp nâng cấp pod mà không sao chép lại trọng số.


Backend dùng image `python:3.12-slim`; uv cài dependency từ lockfile, Alembic cập nhật schema và Uvicorn phục vụ cổng 8000. Frontend được build nhiều giai đoạn trên `node:22-alpine`, chỉ đưa standalone bundle của Next.js [13] vào image cuối. Liveness/readiness probe cùng gọi `/health`; biến `NEXT_PUBLIC_API_BASE_URL` giúp bundle gọi đúng API công khai.

5.3 Giao diện và Chức năng

Giao diện cung cấp ba khu vực chính: chẩn đoán mới, cơ sở tri thức và lịch sử. Khách có thể chẩn đoán nhanh; tài khoản đăng nhập bằng JWT HS256 thời hạn mặc định 24 giờ để lưu lịch sử cá nhân. Flow xác thực là **đăng nhập** → **lưu JWT** → **gọi /auth/me** → **gửi dự đoán kèm Bearer token** → **xem lịch sử theo tài khoản**. Khi token hết hạn hoặc API trả 401, frontend xóa phiên và yêu cầu đăng nhập lại. Hình 13 minh họa trang chính và hộp thoại xác thực.



(a) Trang chẩn đoán



(b) Đăng nhập tài khoản


Hình 13: Giao diện chẩn đoán và xác thực người dùng

Người dùng có thể kéo-thả, chọn tệp hoặc nhấn nút camera. Trên thiết bị di động, thuộc tính **capture** ưu tiên camera sau; ảnh được kiểm tra định dạng, dung lượng và hiển thị preview trước khi gửi. Kết quả gồm tên bệnh Việt-Anh, cây trồng, độ tin cậy, top-5, độ trễ và khuyến nghị; trường hợp độ tin cậy thấp được cảnh báo để tránh xem dự đoán như kết luận chuyên môn. Hình 14 minh họa kết quả trên ảnh cà phê.


Cơ sở tri thức trong Hình 15 bao phủ tám nhãn với mô tả, triệu chứng, nguyên nhân, biện pháp xử lý, phòng ngừa và nguồn đối chiếu. Lịch sử yêu cầu JWT, phân trang theo tài khoản và hiển thị ảnh, nhãn, độ tin cậy, thời điểm cùng khuyến nghị mở rộng; ảnh được truy xuất bằng URL MinIO có thời hạn. FastAPI đồng thời công bố đặc tả OpenAPI tại /docs; ảnh Swagger và trang tri thức chi tiết được chuyển sang Phụ lục A để tránh làm gián đoạn luồng báo cáo chính.

5.4 Triển khai trên GCP

Ứng dụng chạy trên một VM Ubuntu 22.04 LTS của GCP. k3s [11] giảm chi phí so với cụm Kubernetes được quản lý nhiều node; Helm [12] quản lý namespace và release `plant-disease`. Frontend/backend dùng Deployment; PostgreSQL, MinIO và Redis dùng StatefulSet; PostgreSQL



Hình 14: Kết quả dự đoán và khuyến nghị cho ảnh lá cà phê



Hình 15: Danh sách cơ sở tri thức bệnh trên lúa và cà phê


có CronJob sao lưu lúc 02:00 và giữ bảy bản gần nhất. Các cấu hình lưu trữ chính được tổng hợp trong Bảng 14.

Bảng 14: Workload và lưu trữ trên cụm k3s

Workload		Kiểu tài nguyên	Lưu trữ	Dữ liệu chính
Frontend và Backend		Deployment	Model 10 GiB	Bundle Next.js, API và model ONNX.
PostgreSQL		StatefulSet	20 GiB	Tài khoản và lịch sử chẩn đoán.
MinIO		StatefulSet	30 GiB	Ảnh người dùng tải hoặc chụp.
Redis và Backup		StatefulSet và CronJob	1 GiB/5 GiB	Cache dự phòng và bản sao PostgreSQL.

Traefik định tuyến / đến frontend và /api/v1, /health, /docs đến backend. DuckDNS ánh xạ tên miền công khai; cert-manager dùng ACME HTTP-01 của Let's Encrypt để cấp chứng chỉ plant-disease-tls, nên giao diện và API cùng hoạt động qua HTTPS. Secret JWT, PostgreSQL và MinIO được truyền khi deploy, không ghi trực tiếp trong repository.


Workflow deploy.yml thực hiện chuỗi **lint/test** → **build image** → **push GHCR** → **Helm deploy qua SSH** → **smoke test**. Image được gắn tag SHA để truy vết; smoke test kiểm tra rollout, /health, tri thức và đăng ký tài khoản. Hình 16 cho thấy năm job lint, test, build, deploy và smoke test đều hoàn tất thành công.



Hình 16: Các bước CI/CD hoàn tất thành công trên GitHub Actions

5.4.1 Minh chứng trạng thái vận hành

Sau triển khai, nhóm kiểm tra node, pod, service, ingress, PVC và Helm release. Hình 17 cho thấy node `plant-demo-k3s` ở trạng thái `Ready`; các workload ở trạng thái `Running`; job sao lưu đã `Completed`; ingress công bố cổng 80/443 và Helm release ở trạng thái `deployed`.



```
k3s-deploy@plant-demo-k3s — production status
Captured: 2026-07-17T07:41:00+00:00

k3s-deploy@plant-demo-k3s:~$ kubectl get nodes -o wide
NAME                STATUS  ROLES    AGE   VERSION   INTERNAL-IP   OS-IMAGE             CONTAINER-RUNTIME
plant-demo-k3s      Ready   control-plane  9d    v1.36.2+k3s1  10.148.0.2    Ubuntu 22.04.5 LTS   containerd://2.3.2-k3s2

Workloads — namespace plant-disease
k3s-deploy@plant-demo-k3s:~$ kubectl -n plant-disease get pods -o wide
NAME                READY   STATUS    RESTARTS   AGE   NODE
minio-0             1/1    Running   0           3d2h  plant-demo-k3s
plant-disease-backend-77bfdc5d7-cvypm  1/1    Running   0           19m   plant-demo-k3s
plant-disease-frontend-5945465468-lqzdz 1/1    Running   0           19m   plant-demo-k3s
plant-disease-pg-backup-29734680-d6dkm  0/1    Completed 0           2d5h  plant-demo-k3s
plant-disease-pg-backup-29736120-zqng5  0/1    Completed 0           29h   plant-demo-k3s
plant-disease-pg-backup-29737560-cqjph  0/1    Completed 0           5h41m plant-demo-k3s
postgres-0          1/1    Running   0           3d2h  plant-demo-k3s
redis-0             1/1    Running   0           3d20h plant-demo-k3s

Ingress
k3s-deploy@plant-demo-k3s:~$ kubectl -n plant-disease get ingress
NAME                CLASS    HOSTS                                ADDRESS   PORTS   AGE
plant-disease       traefik  plant-disease-demo.duckdns.org      10.148.0.2  80, 443  9d

Helm release
k3s-deploy@plant-demo-k3s:~$ helm list -n plant-disease
NAME                NAMESPACE    REVISION    STATUS    CHART               APP VERSION
plant-disease       plant-disease 22          deployed  plant-disease-0.1.0 0.1.0
```

Hình 17: Trạng thái cụm k3s và Helm release trên GCP

5.5 Đánh giá và Giới hạn Triển khai

Chuỗi giao diện-API-ONNX-tri thức-PostgreSQL-MinIO đã hoạt động trên cloud công khai; Docker, Helm, probe, lưu trữ bền vững, sao lưu và CI/CD nâng khả năng tái lập. Tuy nhiên, cụm một node vẫn là điểm lỗi đơn; volume `local-path` không replication; frontend/backend chỉ có một replica; Redis chưa tham gia luồng nghiệp vụ; CORS còn cho phép mọi origin; smoke test chưa bao phủ dự đoán ảnh đầu-cuối. Hướng mở rộng là dùng cụm nhiều node và storage replication, tăng replica stateless, giới hạn CORS, tự động phân phối model, bổ sung quan sát hệ thống và đưa ảnh mẫu vào smoke test.

6 Kết luận

6.1 Tóm tắt Kết quả

Đồ án đã nghiên cứu và xây dựng thành công hệ thống phân vùng thực thể chẩn đoán bệnh trên lá cây nông nghiệp đặc sản lúa và cà phê tại Việt Nam. Kết quả đạt được so với các mục tiêu đề ra ban đầu được tóm tắt như sau:

- Xây dựng và chuẩn hóa thành công tập dữ liệu gồm 7.149 ảnh thực địa sạch cho cả cây lúa và cây cà phê sau khi loại bỏ các ảnh trùng lặp và ảnh mờ nhòe bằng thuật toán mã băm MD5 kết hợp kiểm tra phương sai Laplacian. Tập dữ liệu chứa 8 lớp nhãn chi tiết với các vết bệnh được khoanh vùng tỉ mỉ ở cấp độ điểm ảnh.
- Huấn luyện và đánh giá đối chiếu thực nghiệm 5 kiến trúc phân vùng thực thể hiện đại bao gồm hai hướng tiếp cận chính là mạng thần kinh tích chập và mạng thị giác máy tính dựa trên cơ chế tập trung.
- Lựa chọn mô hình YOLO26-seg làm mô hình tối ưu cho triển khai thực tế. Bằng việc áp dụng phương pháp tinh chỉnh siêu tham số thông qua thuật toán dừng sớm bất đồng bộ kết hợp Ray Tune, hiệu năng của mô hình được cải thiện thêm hơn 2% độ chính xác mAP@50 trên cả hai miền dữ liệu, đạt lần lượt 84,81% ở lúa và 92,34% ở cà phê.
- Tối ưu hóa suy luận bằng cách lượng tử hóa mô hình sang định dạng ONNX. Qua đó, kích thước mô hình giảm đáng kể xuống còn 6,23 MB và thời gian suy luận trên CPU trung bình chỉ mất 19,85 ms đối với ảnh cà phê và 65,41 ms đối với ảnh lúa.
- Xây dựng hoàn chỉnh hệ thống ứng dụng web đa thành phần, hỗ trợ nông dân tải hoặc chụp ảnh chẩn đoán vết bệnh theo thời gian thực, tích hợp cơ sở dữ liệu lịch sử và hệ thống khuyến nghị tri thức chuyên gia nông nghiệp Việt Nam.
- Đóng gói và triển khai thành công ứng dụng trên môi trường đám mây sử dụng cụm Kubernetes k3s trên máy ảo GCP, cấu hình Traefik Ingress và bảo mật HTTPS, đồng thời tự động hóa toàn bộ quy trình bằng hệ thống tích hợp và triển khai liên tục.

6.2 Hạn chế

Mặc dù đã đạt được nhiều kết quả khả quan về cả độ chính xác của mô hình lẫn tính khả thi của hệ thống triển khai, đồ án vẫn tồn tại một số hạn chế cần được thẳng thắn nhìn nhận để

cải thiện trong tương lai:

- Sự mất cân bằng giữa các lớp dữ liệu vẫn còn khá lớn. Điển hình là bệnh phấn trắng trên cây cà phê chỉ chiếm một tỷ lệ rất nhỏ trong tập dữ liệu thu thập, làm giảm khả năng học và nhận diện các vết bệnh này của mô hình so với các bệnh phổ biến như rỉ sắt hay sâu đục lá.
- Mô hình chẩn đoán vẫn có xu hướng dự đoán sai hoặc giảm độ chính xác khi gặp các hình ảnh thực tế có điều kiện ánh sáng cực đoan ngoài đồng ruộng như ánh nắng gắt trực diện tạo bóng lóa, hoặc ảnh chụp ngược sáng mạnh làm mất chi tiết màu sắc đặc trưng của vết bệnh.
- Hạ tầng triển khai trên đám mây hiện đang vận hành dưới dạng cụm đơn node. Điều này dẫn đến nguy cơ cao về điểm lỗi đơn, nghĩa là nếu máy chủ vật lý gặp sự cố, toàn bộ dịch vụ sẽ ngừng hoạt động.
- Hệ thống lưu trữ tập tin hình ảnh người dùng tải lên và cơ sở dữ liệu lịch sử chẩn đoán chưa được cấu hình cơ chế sao lưu dự phòng phân tán và nhân bản dữ liệu tự động giữa nhiều vùng lưu trữ khác nhau.
- Trình kiểm thử khối trong quy trình tự động hóa chưa bao phủ hết các ca kiểm thử suy luận ảnh thực tế từ đầu đến cuối, dẫn đến việc khó phát hiện sớm các lỗi tích hợp mô hình phát sinh sau mỗi lần cập nhật mã nguồn backend.

6.3 Hướng phát triển

Nhằm khắc phục các hạn chế nêu trên và nâng cao hơn nữa giá trị thực tiễn của đề án, nhóm đề xuất các hướng nghiên cứu và phát triển tiếp theo như sau:

- Tiếp tục mở rộng quy mô tập dữ liệu thực địa, tập trung thu thập hình ảnh của các lớp bệnh thiểu số để giải quyết triệt để vấn đề mất cân bằng lớp. Nghiên cứu áp dụng các phương pháp sinh ảnh hiện đại nhằm tạo thêm các mẫu bệnh đa dạng trong các điều kiện ánh sáng khác nhau.
- Khảo sát và thử nghiệm các kiến trúc phân vùng thực thể thể hệ mới có khả năng học đặc trưng kết cấu tốt hơn, hoặc tích hợp thêm mô hình ngôn ngữ lớn thị giác để hỗ trợ nông dân tương tác hỏi đáp thông tin bệnh học một cách trực quan, sinh động.

- Nâng cấp hạ tầng đám mây lên cụm Kubernetes nhiều node phân tán, sử dụng các giải pháp lưu trữ bền vững có hỗ trợ cơ chế nhân bản dữ liệu tự động nhằm loại bỏ hoàn toàn điểm lỗi đơn và nâng cao khả năng chịu lỗi của hệ thống.
- Tối ưu hóa phân phối tải cho backend bằng cách thiết lập cơ chế tự động mở rộng quy mô dựa trên lưu lượng truy cập thực tế, đồng thời giới hạn chính sách chia sẻ tài nguyên nguồn gốc chéo để đảm bảo an toàn thông tin cho API backend.
- Bổ sung hệ thống giám sát và cảnh báo tự động để theo dõi liên tục hiệu năng hoạt động của mô hình suy luận và tài nguyên hệ thống trên môi trường production, giúp phát hiện sớm các hiện tượng lệch dữ liệu theo thời gian.


Tài liệu tham khảo

- [1] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *European Conference on Computer Vision (ECCV)*, pages 213–229. Springer, 2020.
- [2] Bowen Cheng, Ishan Misra, Alexander G Schwing, Alexander Kirillov, and Rohit Girdhar. Masked-attention mask transformer for universal image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1290–1299, 2022.
- [3] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2961–2969, 2017.
- [4] Glenn Jocher and Ayush Chaurasia. YOLO real-time instance segmentation architecture and best practices. *Ultralytics Technical Reports*, 2024.
- [5] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics YOLO, 2023.
- [6] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4015–4026, 2023.
- [7] Richard Liaw, Eric Liang, Robert Nishihara, Philipp Moritz, Joseph E Gonzalez, and Ion Stoica. Tune: A research platform for distributed model selection and training. In *ICML AutoML Workshop*, 2018.
- [8] Wenyu Lv, Yian Zhao, Shangliang Xu, Jiacheng Wei, Guanzhong Wang, Cheng Cui, Yune Du, Qingqing Dang, and Shengyu Liu. DETRs beat YOLOs on real-time object detection. *arXiv preprint arXiv:2304.08069*, 2023.
- [9] Microsoft. Onnx runtime documentation. <https://onnxruntime.ai/docs/>, 2026. Truy cập ngày 17/07/2026.
- [10] Roboflow. Rf-detr: A real-time object detection transformer, 2024. Accessed: 2025.
- [11] SUSE. K3s documentation. <https://docs.k3s.io/>, 2026. Truy cập ngày 17/07/2026.

- [12] The Helm Authors. Helm documentation. <https://helm.sh/docs/>, 2026. Truy cập ngày 17/07/2026.
- [13] Vercel. Next.js documentation. <https://nextjs.org/docs>, 2026. Truy cập ngày 17/07/2026.
- [14] Chaoning Zhang, Dongshen Han, Yu Qiao, Jung Hee Kim, Sung-Ho Bae, Seungkyu Lee, and Choong Seon Hong. Faster segment anything: Towards lightweight SAM for mobile applications. *arXiv preprint arXiv:2306.14289*, 2023.
- [15] Junlong Zhang, Yanpeng Sun, Qian Zhang, and Xiaosong Zhang. Mobilesam: Fast segment anything. *arXiv preprint arXiv:2306.14289*, 2023.

A Minh chứng bổ sung cho Chương 5

Phụ lục này lưu các giao diện kỹ thuật và màn hình chi tiết đã được lược khỏi Chương 5 nhằm bảo đảm giới hạn trang của phần báo cáo chính, được minh họa chi tiết tại Hình 18.



(a) Swagger UI và các nhóm endpoint

(b) Trang tri thức bệnh chi tiết

Hình 18: Tài liệu API và nội dung cơ sở tri thức mở rộng