

Hệ thống phân vùng thực thể chẩn đoán bệnh trên lá cây nông nghiệp đặc sản cà phê và lúa

CSC14005 - Nhập môn học máy

Sinh viên thực hiện:

Nguyễn Hồ Anh Tuấn - 23120185

Lê Xuân Trí - 23120099

Đàm Tiến Đạt - 23120118

Tổng Thanh Phúc - 23120158

Dương Tuấn Anh - 23120208

Giảng viên hướng dẫn:

Thầy Bùi Tiến Lên

Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM

Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận
- 7 Tài liệu tham khảo

Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận
- 7 Tài liệu tham khảo

1.1. Phân tích Vấn đề - Tính cấp thiết

Bối cảnh nông nghiệp Việt Nam

Lúa gạo và cà phê Robusta là hai nông sản đặc sản xuất khẩu chủ lực của Việt Nam. Dịch bệnh hại lá thường xuyên đe dọa nghiêm trọng đến sinh kế của hàng triệu hộ nông dân tại Đồng bằng sông Cửu Long và Tây Nguyên.

Thách thức trong canh tác

Nông dân khó tiếp cận chuyên gia bệnh học, thường chẩn đoán cảm quan dẫn đến sử dụng sai hoặc lạm dụng thuốc bảo vệ thực vật. Điều này làm tăng chi phí và gây ô nhiễm môi trường nghiêm trọng.

1.1. Phân tích Vấn đề - Phát biểu bài toán

Bài toán được mô hình hóa dưới dạng phân vùng thực thể (*instance segmentation*) với:

- Đầu vào: Ảnh lá cây nông nghiệp $I \in \mathbb{R}^{H \times W \times 3}$
- Đầu ra: Tập hợp K thực thể bệnh $E = \{e_1, e_2, \dots, e_K\}$

Trong đó, mỗi thực thể vết bệnh $e_k = (b_k, c_k, m_k)$ bao gồm hộp bao b_k , nhãn c_k và mặt nạ m_k .

Thách thức trong điều kiện thực tế bao gồm vết bệnh nhỏ trên nền phức tạp, độ tương đồng thị giác cao ở giai đoạn sớm, và điều kiện ánh sáng tự nhiên biến động mạnh.

1.2. Mục tiêu của Đề án


Định lượng & Học máy

Xây dựng bộ dữ liệu 7.149 ảnh thuộc 8 lớp bệnh. Huấn luyện so sánh hiệu năng 5 kiến trúc phân vùng thực thể, và tinh chỉnh siêu tham số (Ray Tune & ASHA) nhằm đạt độ chính xác tối ưu.

Thực tiễn & Triển khai

Phát triển ứng dụng Web chẩn đoán thời gian thực với độ trễ dưới 200 ms/ảnh. Triển khai cụm Kubernetes (k3s) trên GCP có chứng chỉ bảo mật SSL và tự động hóa CI/CD.

1.3. Tổng quan về Phương pháp



Hình 1: Quy trình phát triển hệ thống end-to-end

Hệ thống được thiết kế theo quy trình end-to-end khép kín, đảm bảo tính nhất quán từ dữ liệu thô được thu thập trong môi trường thực tế cho tới ứng dụng chạy thực tế trên hạ tầng đám mây.


Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu**
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận
- 7 Tài liệu tham khảo

2.1. Nguồn và phương pháp thu thập

Nguồn và mở rộng dữ liệu


- Kế thừa từ hai bộ tập dữ liệu có sẵn: Rice Diseases Image Dataset và Detect Disease On Coffee Leaves.
- Thu thập bổ sung qua hình thức cào dữ liệu từ các trang web, blog chuyên ngành bằng công cụ Crawl4AI.
- Khám phá và lọc URL tự động nhờ DuckDuckGo và Serper.dev.



2.1. Nguồn và phương pháp thu thập

Vòng lặp có sự tham gia của con người

- Gán nhãn theo hướng vòng lặp có sự tham gia của con người.
- AI đề xuất nhãn (Gemma 4) và tạo pseudo-mask tự động bằng mô hình SAM 3.
- Kiểm duyệt thủ công trên công cụ Streamlit để xác nhận hoặc sửa nhãn.



2.1. Nguồn và phương pháp thu thập

Quy mô bộ dữ liệu hợp nhất

Tập dữ liệu thu thập được bao gồm 7.300 ảnh với tổng cộng 7.562 COCO format annotation phục vụ cho bài toán instance segmentation.

Bảng 1: Quy mô bộ dữ liệu hợp nhất

Miền cây trồng	Số lượng ảnh	Số annotation
Lúa	3.421	3.720
Cà phê	3.879	3.842
Tổng cộng	7.300	7.562

2.2. Tiền xử lý và làm sạch

Quy trình kiểm duyệt hai bước

Dữ liệu thô thu thập từ nhiều nguồn được lọc qua quy trình kiểm duyệt chất lượng nghiêm ngặt:

- 1 Khử trùng lặp: tính toán hàm băm MD5 trên nội dung nhị phân để phát hiện và loại bỏ chính xác các ảnh trùng lặp hoàn toàn.
- 2 Lọc ảnh mờ nhòe: đánh giá độ sắc nét dựa trên phương sai của phép biến đổi Laplacian với ngưỡng loại bỏ $\tau = 100$.

Bảng 2: Kết quả làm sạch toàn bộ tập ảnh

Lý do xử lý	Số ảnh	Tỷ lệ (%)
Ảnh trùng lặp	1	0,01
Ảnh mờ nhòe	150	2,05
Giữ lại sử dụng	7.149	97,93

2.2. Tiền xử lý và làm sạch

Phân bố chi tiết số ảnh sau khi làm sạch

Bảng 3: Phân bố số lượng ảnh và tỷ lệ theo lớp và miền sau làm sạch


Miền dữ liệu	Lớp bệnh	Số lượng ảnh	Tỷ lệ trong miền (%)
Lúa (3.351 ảnh)	Lá khỏe mạnh	1.472	43,93
	Bệnh đạo ôn	777	23,19
	Sâu gai	571	17,04
	Bệnh đốm nâu	531	15,85
Cà phê (3.798 ảnh)	Bệnh rỉ sắt	1.387	36,52
	Sâu đục lá	1.200	31,60
	Bệnh đốm rong	949	24,99
	Bệnh phấn trắng	262	6,90

2.3. Phân tích và khám phá dữ liệu

Mất cân bằng lớp và hình học ảnh

- Mất cân bằng lớp: tỷ số mất cân bằng $IR = N_{\max}/N_{\min}$ trên Lúa là 2,77 và trên Cà phê là 5,28 (lớp phần trắng chỉ chiếm 6,9%).
- Chênh lệch độ phân giải: ảnh lúa trung bình 2.031×2.026 px, chủ yếu vuông; ảnh cà phê nhỏ hơn rõ rệt, 971×1.154 px, thiên về khung dọc.

⇒ Chuẩn hóa kích thước ảnh giữ nguyên tỷ lệ khung hình thực bằng kỹ thuật letterbox. Sử dụng các kỹ thuật tăng cường dữ liệu.




Hình 2: Phân bố số lượng và tỷ lệ các lớp bệnh

2.3. Phân tích và khám phá dữ liệu

Màu sắc và cặp bệnh dễ nhầm lẫn

- Đặc trưng chiếu sáng: ảnh Lúa sáng rõ rệt (độ sáng trung bình 198 - 202) so với ảnh Cà phê (116 - 129). Kênh Green chiếm ưu thế nhưng độ tương phản giữa các lớp giao thoa mạnh.
- Khoảng cách Bhattacharyya D_B trên histogram RGB chuẩn hóa:
 - Lúa: cặp đốm nâu và đạo ôn có D_B nhỏ trên cả 3 kênh (lớn nhất ở kênh Red với $D_B = 0,132$).
 - Cà phê: cặp đốm rong và rỉ sắt có phân bố màu gần trùng khớp hoàn toàn ($D_B \approx 0,003 - 0,005$).

⇒ Mô hình không thể dựa vào màu toàn cục mà bắt buộc phải học kết cấu cục bộ cùng ngữ cảnh không gian.



Hình 3: Histogram RGB của các cặp bệnh dễ nhầm lẫn

Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình**
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận
- 7 Tài liệu tham khảo

3.1. Chuẩn bị dữ liệu cho mô hình

Phân chia tập dữ liệu chống rò rỉ

Tập dữ liệu sạch gồm 7.149 ảnh được phân chia thành ba tập theo tỷ lệ chuẩn 70 : 15 : 15 bằng kỹ thuật Stratified Sampling.

Bảng 4: Phân bố số lượng ảnh theo tập con, miền và lớp bệnh

Miền dữ liệu	Train (70%)	Val (15%)	Test (15%)	Tổng cộng
Lúa	2.346	502	503	3.351
Cà phê	2.658	570	570	3.798
Tổng toàn cục (8 lớp)	5.004	1.072	1.073	7.149

3.1. Chuẩn bị dữ liệu cho mô hình

Tiền xử lý và tăng cường dữ liệu

Để tăng khả năng tổng quát hóa và chống overfitting, nhóm áp dụng các kỹ thuật chuẩn hóa và tăng cường dữ liệu trong quá trình huấn luyện:

Bảng 5: Các kỹ thuật tiền xử lý và tăng cường dữ liệu

Phương pháp	Chi tiết thiết lập và tác dụng
Letterbox	Đưa ảnh về kích thước 640×640 hoặc 256×256 px giữ nguyên tỷ lệ khung hình thực, tránh méo dạng vùng bệnh.
Cắt và đổi kích thước Lật hình học	Cắt và thay đổi kích thước ngẫu nhiên với tỷ lệ diện tích từ 0,75 đến 1,0. Lật ngang với xác suất $p = 0,5$, lật dọc với xác suất $p = 0,2$.
Biến đổi affine	Xoay ngẫu nhiên trong khoảng góc $\pm 30^\circ$.
Biến thiên quang học	Điều chỉnh ngẫu nhiên độ sáng và màu sắc ảnh.
Trộn mẫu (<i>MixUp</i>)	Mixup với hệ số $\alpha = 0,4$.

3.2. Lựa chọn và kiến trúc mô hình

Nhóm khảo sát, huấn luyện và so sánh năm kiến trúc tiên tiến thuộc hai trường phái Convolutional Neural Network (CNN) và Vision Transformer (ViT) nhằm tối ưu điểm cân bằng giữa độ chính xác và tốc độ suy luận:

Bảng 6: Tổng quan năm kiến trúc cho bài toán instance segmentation

Mô hình	Họ	Đặc điểm nổi bật và lý do lựa chọn
Mask R-CNN [1]	CNN	Kiến trúc hai giai đoạn kinh điển, mang lại độ chính xác cao, được chọn làm baseline đối chiếu hiệu suất.
YOLO26-seg [2, 3]	CNN	Kiến trúc một giai đoạn với tốc độ thời gian thực xuất sắc, cỡ nano tối ưu điểm cân bằng chính xác - tốc độ.
RF-DETR [4, 5]	ViT	Thiết kế end-to-end loại bỏ NMS, DINOv2 feature extraction, real-time Transformer.
MobileSAM [6, 7]	ViT	Phiên bản thu gọn siêu nhẹ của SAM, khả năng zero-shot với câu lệnh đầu vào, tối ưu cho edge devices.
Mask2Former [8]	ViT	Kiến trúc phân vùng hợp nhất dựa trên mask classification, đạt hiệu năng đa tác vụ vượt trội.

3.3. Cấu hình huấn luyện

Thiết lập cấu hình chung

Bảng 7: Cấu hình huấn luyện chung

Tham số	Giá trị thiết lập
Phần cứng GPU	NVIDIA Tesla T4
Tỷ lệ chia dữ liệu	70 : 15 : 15
Thuật toán tối ưu	AdamW
Effective batch size	8
Số epoch tối đa	50
Dừng sớm	5
Seed	42

Tham số riêng theo kiến trúc

Bảng 8: Cấu hình riêng cho từng mô hình

Mô hình	l_{r0}	Kích thước	Ghi chú kỹ thuật
Mask R-CNN	$1 \cdot 10^{-4}$	256×256	Batch 2, grad acc 4
YOLO26-seg	$8 \cdot 10^{-4}$	640×640	Batch 8
RF-DETR	$1 \cdot 10^{-4}$	640×640	Batch 2, grad acc 4
MobileSAM	$1 \cdot 10^{-5}$	1024×1024	Batch 2, grad acc 4
Mask2Former	$5 \cdot 10^{-5}$	384×384	Batch 4, grad acc 2

*Ghi chú: Batch: batch size, grad acc: tích lũy đạo hàm.

3.4. Tinh chỉnh siêu tham số

Tối ưu tự động bằng Ray Tune

- Tinh chỉnh siêu tham số cho mô hình tốt nhất YOLO26-seg bằng Ray Tune.
- Áp dụng thuật toán lập lịch bất đồng bộ ASHA.
- Đánh giá song song nhiều cấu hình thử nghiệm, dừng sớm các cấu hình kém hiệu quả ngay từ những epoch đầu giúp tối ưu hóa tài nguyên tính toán.
- Thực nghiệm 20 thử nghiệm độc lập trên không gian sáu siêu tham số cốt lõi.

Bảng 9: Không gian tìm kiếm siêu tham số

Siêu tham số	Phân phối	Khoảng/Tập giá trị
Learning rate (lr_0)	Log-uniform	$[1 \cdot 10^{-5}, 1 \cdot 10^{-2}]$
Momentum	Uniform	$[0, 85, 0, 95]$
Weight decay	Log-uniform	$[1 \cdot 10^{-5}, 1 \cdot 10^{-3}]$
Warmup epochs	Choice	$\{1, 2, 3\}$
Hệ số khung bao λ_{box}	Uniform	$[5, 0, 10, 0]$
Hệ số phân loại λ_{cls}	Uniform	$[0, 3, 0, 8]$

Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận**
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận
- 7 Tài liệu tham khảo

4.1. So sánh hiệu năng 5 mô hình

Bảng 10: Tóm tắt kết quả mAP@50 và Thời gian suy luận

Mô hình	Tập Lúa (Rice)		Tập Cà phê (Coffee)	
	mAP@50	Thời gian (ms)	mAP@50	Thời gian (ms)
MobileSAM	0.5637	1487.54	0.6923	1616.84
Mask R-CNN	0.5966	760.50	0.9480	702.36
Mask2Former	0.6971	96.81	0.9200	62.88
RF-DETR	0.7038	198.31	0.8428	70.31
YOLO26-seg	0.8247	65.72	0.9012	20.21


- YOLO26-seg đạt độ chính xác mAP đứng hạng đầu trên tập Lúa và hạng ba trên tập Cà phê.
- YOLO26-seg sở hữu tốc độ suy luận vượt trội nhất (20 - 65 ms/ảnh).

4.2. Đường cong học tập

Phân tích hội tụ

Quá trình huấn luyện YOLO26-seg qua 50 epochs:

- Hàm mất mát giảm ổn định, hội tụ tốt sau epoch 40.
- Chỉ số mAP@50 tăng nhanh trong 30 epochs đầu và bão hòa ổn định ở các epoch cuối.
- Không xảy ra hiện tượng nhiễu động mạnh hoặc overfitting sớm.



Tập Lúa

Tập Cà phê

Hình 4: Đường cong học tập (Loss và mAP) của YOLO26-seg

4.3. Kết quả tinh chỉnh YOLO26-seg bằng RayTune và ASHA


Bảng 11: So sánh trước và sau tinh chỉnh siêu tham số

Tập dữ liệu	Trạng thái	mAP@50	mAP@50:95	mIoU	Dice	Inference (ms)	Size (MB)
Lúa	Baseline	0.8247	0.7891	0.8543	0.8712	65.72	6.23
	Tuned	0.8481	0.8034	0.8697	0.8856	65.41	6.23
Cà phê	Baseline	0.9012	0.8637	0.8921	0.9087	20.21	6.23
	Tuned	0.9234	0.8845	0.9053	0.9192	19.85	6.23


*Ghi chú: Kích thước 6,23 MB đo ở định dạng trọng số PyTorch (.pt) gốc.

- Phương pháp tìm kiếm kết hợp thuật toán loại bỏ sớm ASHA giúp tăng hơn 2% mAP@50 trên cả hai miền dữ liệu.

4.4. Ma trận nhầm lẫn của YOLO26-seg



Tập Lúa



Tập Cà phê

Hình 5: Ma trận nhầm lẫn chuẩn hóa của mô hình YOLO26-seg

- Nhầm lẫn điển hình: Đốm nâu (BrownSpot) $\leftrightarrow$ Sâu gai (Hispa) trên lúa.
- Cà phê: Nhầm lẫn nhẹ giữa Rỉ sắt (Rust) $\leftrightarrow$ Đốm rong (AlgalLeafSpot).

4.5. Kết quả lượng tử hóa mô hình

Bảng 12: So sánh trước và sau lượng tử hóa 8 bit

Tập dữ liệu	Trạng thái	mAP@50	mAP@50:95	mIoU	Dice	Inference (ms)	Size (MB)
Lúa	Tuned (ONNX FP32)	0.8481	0.8034	0.8697	0.8856	65.41	94.8
	8 bit (ONNX INT8)	0.8411	0.7831	0.8599	0.8812	65.34	23.77
Cà phê	Tuned (ONNX FP32)	0.9234	0.8845	0.9053	0.9192	19.85	94.8
	8 bit (ONNX INT8)	0.9221	0.8744	0.9030	0.9112	17.85	23.77

- Lượng tử hóa 8 bit giúp giảm gần 4 lần dung lượng mô hình và cải thiện nhẹ tốc độ suy luận. Độ chính xác giảm nhẹ trên cả hai tập.

Mục lục


- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng**
- 6 Kết luận
- 7 Tài liệu tham khảo

5.1. Kiến trúc hệ thống và tích hợp mô hình

Mô hình tổng thể

Tích hợp mô hình YOLO26-seg đã lượng tử hóa dạng ONNX để thực thi suy luận trên CPU.

Hệ thống chia làm các thành phần độc lập: giao diện Next.js, backend FastAPI điều phối ONNX Runtime, lưu trữ với PostgreSQL, MinIO và Redis.




Hình 6: Kiến trúc tổng thể hệ thống trên GCP và k3s

5.2. Giao diện ứng dụng và luồng chẩn đoán

Các tính năng chính

Hệ thống hỗ trợ xác thực tài khoản qua JWT thời hạn 24 giờ.

Nông dân tải ảnh hoặc chụp trực tiếp từ camera. Ảnh được gửi đến API sử dụng mô hình YOLO26-seg để dự đoán nhãn bệnh kèm độ tin cậy. Kết quả được lưu lịch sử và hiển thị khuyến nghị từ chuyên gia.



Hình 7: Giao diện kết quả chẩn đoán bệnh lá cà phê

5.3. Triển khai hạ tầng đám mây và k3s


Hạ tầng Kubernetes

Workload được container hóa toàn bộ và quản lý bởi k3s trên máy ảo GCP.

Cấu hình cụm dịch vụ qua Helm Chart, định tuyến Ingress Traefik và tự động cấp chứng chỉ SSL HTTPS Let's Encrypt qua cert-manager để bảo mật toàn diện.

Web đã triển khai:

<https://plant-disease-demo.duckdns.org>



```
k3s-deploy@plant-demo-k3s:~$ kubectl get nodes -o wide
NAME                STATUS    ROLES    AGE   VERSION   INTERNAL-IP   OS-IMAGE               CONTAINER-RUNTIME
plant-demo-k3s      Ready    control-plane   9d    v1.30.2+k3s1  10.148.0.2    Ubuntu 22.04.5 LTS     containerd://2.3.2-k3s2

Workloads - namespace plant-disease
k3s-deploy@plant-demo-k3s:~$ kubectl -n plant-disease get pods -o wide
NAME                READY    STATUS    RESTARTS   AGE   NODE
minio-0             1/1     Running   0           3d2h  plant-demo-k3s
plant-disease-backend-77b6dc5d7-cvypm  1/1     Running   0           19m   plant-demo-k3s
plant-disease-frontend-594546348-lqpdz  1/1     Running   0           19m   plant-demo-k3s
plant-disease-pg-backup-29734688-dsdkm  0/1     Completed 0           2d5h  plant-demo-k3s
plant-disease-pg-backup-29736128-znqz5  0/1     Completed 0           29h   plant-demo-k3s
plant-disease-pg-backup-29737568-cqjsh  0/1     Completed 0           5h41m plant-demo-k3s
postgres-0          1/1     Running   0           3d2h  plant-demo-k3s
redis-0             1/1     Running   0           3d20h plant-demo-k3s

Ingress
k3s-deploy@plant-demo-k3s:~$ kubectl -n plant-disease get ingress
NAME                CLASS    HOSTS                                ADDRESS      PORTS   AGE
plant-disease       traefik  plant-disease-demo.duckdns.org      10.148.0.2   80, 443  9d

Helm release
k3s-deploy@plant-demo-k3s:~$ helm list -n plant-disease
NAME      NAMESPACE   REVISION   STATUS   CHART               APP VERSION
plant-disease  plant-disease  22         deployed plant-disease-0.1.0  0.1.0
```


Hình 8: Trạng thái vận hành của các cụm pod trên k3s

5.3. Quy trình tích hợp và triển khai tự động

Tự động hóa CI/CD

Xây dựng workflow CI/CD hoàn chỉnh trên GitHub Actions, kiểm tra định dạng và chạy kiểm thử mã nguồn.

Đóng gói và đẩy Docker image lên GHCR, kết nối SSH cập nhật Helm Chart tại VM và kiểm tra khép kín qua Smoke Test.



Hình 9: Quy trình CI/CD hoàn tất thành công

Mục lục

- 1 Giới thiệu
- 2 Thu thập và phân tích dữ liệu
- 3 Lựa chọn và huấn luyện mô hình
- 4 Kết quả và Thảo luận
- 5 Xây dựng và Triển khai Ứng dụng
- 6 Kết luận**
- 7 Tài liệu tham khảo

6.1. Tóm tắt kết quả của đề án

Đề án đã đạt được các kết quả chính sau đây:

- Bộ dữ liệu chuẩn hóa: Xây dựng thành công bộ dữ liệu gồm 7.149 ảnh thực địa chất lượng cao của lúa và cà phê sau khi làm sạch bằng MD5 và phương sai Laplacian.
- Mô hình tối ưu: Huấn luyện và tinh chỉnh YOLO26-seg bằng Ray Tune cùng ASHA giúp nâng mAP@50 thêm hơn 2%, lượng tử hóa ONNX giảm dung lượng còn 23,77 MB và suy luận dưới 66 ms trên CPU.
- Triển khai thực tế: Phát triển ứng dụng Web hoàn chỉnh và triển khai lên hạ tầng GCP sử dụng cụm Kubernetes k3s cùng quy trình CI/CD tự động hóa.

6.2. Hạn chế hiện tại của hệ thống

Mặc dù đạt được nhiều kết quả khả quan, hệ thống vẫn tồn tại một số hạn chế kỹ thuật:

- Mất cân bằng dữ liệu: Tập dữ liệu vẫn bị lệch lớp, đặc biệt là số mẫu ảnh của bệnh phần trắng trên cây cà phê còn khá ít (6,9% trong miền).
- Độ bền của mô hình: Độ chính xác chẩn đoán có xu hướng suy giảm dưới các điều kiện ánh sáng thực địa bất lợi (như nắng gắt trực diện hoặc bóng râm dày).
- Hạ tầng đơn node: Hạ tầng đám mây GCP chạy trên máy ảo đơn node nên còn rủi ro về điểm lỗi đơn, chưa cấu hình sao lưu và nhân bản dữ liệu phân tán tự động.

6.3. Hướng phát triển trong tương lai

Nhằm khắc phục các hạn chế và nâng cao giá trị thực tiễn, nhóm đề xuất hướng phát triển tiếp theo:

- Mở rộng dữ liệu và mô hình: Tiếp tục thu thập các mẫu bệnh lớp thiểu số, nghiên cứu các kiến trúc phân vùng mới hoặc tích hợp mô hình ngôn ngữ lớn thị giác (VLM) để hỗ trợ chẩn đoán qua hội thoại.
- Nâng cấp hạ tầng: Chuyển đổi cụm Kubernetes k3s sang multi-node, kết hợp cơ chế lưu trữ bền vững có nhân bản tự động để loại bỏ điểm lỗi đơn.
- Giám sát và tự động hóa: Bổ sung các chính sách bảo mật API (CORS), tự động hóa phân phối model và cài đặt hệ thống giám sát cảnh báo lệch dữ liệu (data drift).

7. Tài liệu tham khảo I



K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask R-CNN,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2961–2969, 2017.



G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLO,” 2023.



G. Jocher and A. Chaurasia, “YOLO real-time instance segmentation architecture and best practices,” *Ultralytics Technical Reports*, 2024.



N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, “End-to-end object detection with transformers,” in *European Conference on Computer Vision (ECCV)*, pp. 213–229, Springer, 2020.



W. Lv, Y. Zhao, S. Xu, J. Wei, G. Wang, C. Cui, Y. Du, Q. Dang, and S. Liu, “DETRs beat YOLOs on real-time object detection,” *arXiv preprint arXiv:2304.08069*, 2023.



C. Zhang, D. Han, Y. Qiao, J. H. Kim, S.-H. Bae, S. Lee, and C. S. Hong, “Faster segment anything: Towards lightweight SAM for mobile applications,” *arXiv preprint arXiv:2306.14289*, 2023.



A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, “Segment anything,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4015–4026, 2023.



B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask transformer for universal image segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1290–1299, 2022.



G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics yolo,” 2023.



R. Liaw, E. Liang, R. Nishihara, P. Moritz, J. E. Gonzalez, and I. Stoica, “Tune: A research platform for distributed model selection and training,” in *ICML AutoML Workshop*, 2018.

7. Tài liệu tham khảo II



Roboflow, "Rf-detr: A real-time object detection transformer," 2024.

Accessed: 2025.



J. Zhang, Y. Sun, Q. Zhang, and X. Zhang, "Mobilesam: Fast segment anything," *arXiv preprint arXiv:2306.14289*, 2023.